

تاب آوری راهبردی تحت عدم قطعیت

تحلیل بازی نظری و پیاده سازی در موتور SEE

سهیل سیاح ورگ
۴۰۲۱۱۱۲۳۷ — دانشکده‌ی مهندسی کامپیوتر

درس نظریه بازی‌ها — نیم سال دوم ۱۴۰۴-۱۴۰۵
استاد درس: دکتر حسین قربان

اگر ادامه‌ی تقابل برای هر دو طرف پرهزینه است،
چرا تقابل ادامه پیدا می‌کند؟

پاسخ یک خطی این گزارش:
چون آستانه‌ی ادامه پایین است — و ادامه دادن، خودش آن آستانه را پایین تر می‌آورد.

سه چیز را نشان می‌دهیم: (۱) این آستانه چیست و عددش چقدر است؛ (۲) چرا مسئله‌ی باور در این بازی دوبعدی است؛
(۳) چرا قوی‌ترین سیگنال بهترین نیست.

$$\Gamma = \langle N, \Theta, p, E, T, H, M, A, \Sigma, D, S, g, G, \varphi, B, X, \mu, \tau, u \rangle$$

◀ نوع خصوصی $\theta_i = (\bar{\rho}_i, \bar{m}_i)$: عزم پایه و ظرفیت مدیریت هزینه؛ ثابت و مشاهده‌نشدنی.

◀ تاب‌آوری e_i^t : حالت نهفته، با $e^{t+1} = e^t - g^t + \xi$ ؛ رسیدن به صفر $\Rightarrow$ خروج اجباری.

◀ اقدام $a_i^t = (\sigma_i^t, d_i^t)$ ، $\sigma \in \{0, .25, .5, .75, 1\}$.

◀ هزینه مؤثر $g_i = \frac{c_i + \alpha_i K_i + r_i}{\bar{m}_i(0.35 + 0.65\hat{e}_i)}$ ؛ $K =$ انبار تعهد عمومی.

◀ دو ارزش پایانی: $B_i = 175(0.5 + 0.3\hat{e}_i + 0.2\bar{\rho}_i)$ و $X_i = x_0 - 5K_i - 8\tilde{\sigma}_j + 20M$

اتحاد کلیدی

$G_i(t) \approx e_i^0 - e_i^t$ — «هزینه‌ی انباشته» و «تاب‌آوری خرج‌شده» یک چیزند.

هزینه‌های گذشته ریخته‌اند، پس مقایسه آینده‌نگر است:

$$q_i^t \geq q^* = \frac{g_i + \varphi_i(\sigma_i) - \Delta X_i}{B_i - X_i}$$

◀ صورت: سوخت + بهای سیگنال + فرسایش گزینه‌ی خروج $(-\Delta X)$.

◀ مخرج: فاصله‌ی جایزه تا گزینه‌ی بیرونی.

حالا عددهای واقعی این جهان:

$$B \in [87.5, 185.5], \quad X \in [-2, 48], \quad g \approx 1.1-1.3$$

$$\Rightarrow q^* \approx \frac{1.12}{150 - 26} \approx \mathbf{0.009}$$

یافته‌ی ۱

خروج داوطلبانه تقریباً هیچ‌وقت بهینه نیست. خروج عقلانی همان خروج اجباری است.

۲. باورها: مسئله‌ی فیلتر فقط دوبعدی است

حالت e_j^t پنهان است، ولی قانونش عمومی است:

$$g_j^t = \text{ramp}(t) \cdot \frac{c_{0j} + \kappa_j \sigma_i + \alpha_j K_j + \eta \sigma_i \sigma_j}{\bar{m}_j (0.35 + 0.65 e_j / e_j^0)}$$

هر چیزی جز $(\bar{m}_j, e_j^0)$ عمومی است $\Rightarrow$ پسین روی مسیر = پسین روی یک نوع دوبعدی.

سه کانال به‌روزرسانی:

۱. بقا: حریف هنوز نرفته $\Rightarrow$ هر نوعی که باید مرده بود حذف می‌شود. دقیق، بدون نیاز به مدل استراتژی حریف.

۲. تک تقاطعی: موضع بلند انتخاب شده شاهد قوی بودن است.

۳. پیشین منتشر شده (نامتقارن).

کمیت	بایاس	MAE	RMSE	MAE پیش‌بینی ثابت
$\hat{e}_j$ (تاب‌آوری پنهان حریف)	+0.0033	0.0511	0.0835	0.1884
$\bar{\rho}_j$ (عزم پایه)	-0.0154	0.1522	0.1836	—

کاهش خطا: 72.9%

و یک فرمول بسته برای زمان فروپاشی که از همین قانون درمی‌آید:

$$T_{\text{فروپاشی}} = \frac{e^0 \bar{m} (0.35x + 0.325x^2)}{R}, \quad x = \hat{e}$$

T نسبت به $\bar{m}$ خطی، نسبت به فشار خام وارون، و نسبت به تاب‌آوری باقی‌مانده محدب — همان «شکنندگی فزاینده».

تعارض اعتبار-انعطاف از سه کانال می گذرد: انبار تعهد $(-5K)$ ، تحقیر $(-8\tilde{\sigma}z)$ ، و قفل نوبت $(\sigma \geq 0.75) \Rightarrow$ مجبور به HOLD).

یافته ۲ — تخفیفی که موتور به تشدید می دهد

موتور φ را فقط وقتی سیگنال تازه تولید شود می گیرد؛ در HOLD هیچ هزینه ای گرفته نمی شود. و عبور از 0.75 دقیقاً همان چیزی است که شما را HOLD می کند.

$$\frac{1}{2}\varphi(0.75) = 0.281\kappa \quad \text{در برابر} \quad \varphi(0.50) = 0.25\kappa$$

هزینه تقریباً برابر، ولی فشار وارد بر حریف به مراتب بیشتر.

$\Rightarrow$ تابع سود نسبت به σ یکنوا نیست؛ $\sigma = 0.5$ بدترین گزینه است.

و عامل آموزش دیده مستقلاً همین را کشف می کند

σ	0.00	0.25	0.50	0.75	1.00
سهم از مراحل	57.7%	29.8%	1.1%	11.3%	0.2%
φ میانگین	0.000	0.146	0.595	1.389	2.416

یک حفره دقیقاً روی $\sigma = 0.5$ از 29.8% به 1.1% سقوط و بعد دوباره به 11.3% بالا. توزیع یکنوا نیست.

و بررسی مستقل استراتژی های ساده همین ترتیب را می دهد:

$$\sigma = 0.75 (47.6) > \sigma = 1.0 (34.4) > \sigma = 0 (11.7) > \sigma = 0.5 (-10.6)$$

گزاره	آماره	نتیجه
۱. دروازه‌ی پایین	میانده‌ی q^* نرخ خروج داوطلبانه $\text{Pr}(\text{خروج})$ بر حسب چارک $\bar{\rho}$ مطلوبیت بر حسب چارک $\bar{\rho}$	0.015 0.9% مراحل $0.36 \rightarrow 0.10$ $54 \rightarrow 90$
۲. سیگنال درونی	سهم $\sigma = 0/0.25/0.5/0.75$	82.2%/0.2%/ 0.2% /17.0%
۳. خروج ساختنی	$\text{Pr}(\text{خروج} \mid M=1) / \text{Pr}(\cdot \mid M=0)$	3.4 ×
۴. گیر افتادن در تعهد خود	$\text{Pr}(\text{خروج})$ بر حسب K	$0.011 \rightarrow$ 0.0006

هر چهار گزاره تایید می‌شوند. گزاره‌های ۲ تا ۴ درباره‌ی ساختار شرطی‌اند و شکل‌دهی پتانسیل پایه سیاست بهینه را عوض نمی‌کند، پس عامل خودش به آن‌ها رسیده است.

(الف) ماژول گم شده

evaluate.py و eval_submission.py از see.tournament.runner می‌کنند — ماژولی که در مخزن نیست. بازسازی‌اش کردیم طبق DESIGN.md بخش ۱۰، بدون دست زدن به فیزیک.

(ب) تله‌ی ابرپارامتر

DESIGN.md می‌گوید راه‌حل «فروپاشی امتیازدهی» این است: $p_self = 0.35$ و $entropy \geq 0.02$ — و پیش‌فرض PPOConfig هم همین است. اما train.py با $p_self = 0.6$ و $entropy = 0.01$ — آن‌ها را بازنویسی می‌کند و همان خرابی را برمی‌گرداند.

اندازه‌گیری: صندلی آمریکا در 100% ایزودها در $t \approx 3$ تسلیم می‌شد.

یافته‌ی چهارم: چرا «تسلیم زودهنگام» گاهی درست است

در برابر حریفی که نمی‌رود (یا در افق $\bar{T} = 40$ به آستانه‌ی خروجش نمی‌رسد)، بازی به مهلت می‌رسد و آنجا $G \approx e^0$:

$$u^{t=3 \text{ خروج در } u} \approx 28 - 4. \quad \text{در برابر} \quad u^{\text{مهلت}} \approx X - G(\bar{T}) \approx 28 - 53 < 0$$

نتیجه

آنچه ما اول «خرابی تسلیم» تشخیص دادیم، در برابر بخشی از استخر یک بهترین پاسخ بود. و به همین دلیل استخر غنی‌شده کمکی نکرد: ما با افزودن حریفانی که نمی‌روند، خروج زودهنگام را جذاب‌تر کردیم. راه‌حل: هماهنگ کردن استخر آموزش با توزیع ارزیابی.

رژیم آموزش	طول اپیزود	u_I	u_U
پیش‌فرض‌های ارائه‌شده	3.2	144.8	30.8
استخر غنی‌شده	5.7	110.9	35.1
هماهنگ با مرجع	10.4	89.6	70.0

مطالعه‌ی حذفی — و یک فرضیه که آزمونش را پاس کرد

پیکربندی	امتیاز کل	ایران	آمریکا
TitForTat (مرجع)	95.5	152.7	38.2
ویژگی + شکل‌دهی، هماهنگ (ارسالی)	89.8	136.3	43.4
فقط شکل‌دهی، هماهنگ	89.8	135.5	44.1
ویژگی + شکل‌دهی، استخر غنی‌شده	84.5	124.8	44.2
فقط شکل‌دهی، پیش‌فرض‌های ارائه‌شده	69.8	91.7	47.9

در رژیم اول، ویژگی‌های باور عملکرد را بهتر نکردند (83.2 در برابر 90.6) — با آنکه خطای برآورد را 72.9% کم می‌کنند.

فرضیه: مشکل کیفیت باور نیست، بودجه‌ی نمونه است (GRU خودش پسین ضمنی دارد؛ ۱۴ ویژگی ورودی را از ۱۶ به ۳۰ بعد می‌برد).

آزمون: با 700 هزار گام و استخر هماهنگ، ویژگی+شکل‌دهی جلو زد و امتیاز TitForTat را از 109.8 به 95.9 پایین آورد. فرضیه تایید شد — و چک‌پوینت ارسالی نظریه‌ی کامل است.

امتیاز هر عامل میانگین مطلوبیت خودش است، و در استخر سه‌تایی هیچ‌کس با خودش بازی نمی‌کند $\Rightarrow$ دو صندلی ما دو مجموعه بازی مجزا می‌بینند:

$$\underbrace{(A + B - b')}_{J_I \text{ صندلی ایران}} + \underbrace{(C + D - d')}_{J_U \text{ صندلی آمریکا}} > R_1 + R_2 = 231.8$$

نسخه	J_I	J_U	مجموع
پایه (بدون جمله‌ی جریمه)	194.3	-5.8	188.5 (می‌بازد)
جریمه‌ی بی‌شرط، یک صندلی	170.8	93.7	264.5
جریمه‌ی شرطی، یک صندلی	123.6	81.6	205.2 (می‌بازد)
شرطی، هر دو صندلی	189.3	84.1	273.4

سه بار شکست خوردیم و بار چهارم بردیم. ولی این کل تحلیل روی استخر اشتباهی بود — اسلاید بعد.

بعد از اولین آپلود: معیار آن نبود که فکر می‌کردیم

یک چک‌پوینت، دو معیار، دو علامت مخالف

evaluate.py (سه عاملی): $+10.7$ برد کلاسی: -0.9

برد با شش حریف مرجع نمره می‌دهد؛ /see فقط دوتایش را دارد. سه‌تای دیگر را از روی DESIGN.md بازسازی و روی عددهای منتشرشده برازش کردیم:

حریف	برد واقعی (ایران/آمریکا)	بازسازی	
Random	113.8 / 119.8	113.8 / 119.8	دقیق
TitForTat	2.7 / 34.3	2.7 / 34.3	دقیق
MasterAgent	-2.7 / 70.1	-2.7 / 70.1	دقیق
Hawk	-58.7 / -12.1	-58.7 / -12.0	دقیق
Dove	135.9 / 144.4	130.6 / 154.8	تقریبی
BayesianThreshold	9.4 / 77.6	35.6 / 82.1	تقریبی

برازش یک چیز نانوشته را هم مشخص کرد: امتیاز هر مرجع شامل بازی با خودش هم هست — برای همین Hawk سوم است نه اول.

۱. استخر آموزش: از $\{\text{TitForTat}, \text{Random}\}$ به همان شش حریف برد. عامل ما هیچ وقت با حریفی که نمی رود تمرین نکرده بود، و مقابل Hawk در صندلی آمریکا -58.7 می گرفت؛ حالا $+4.7$.
۲. جمله‌ی جریمه‌ی تسلیم حذف شد. امتیاز TitForTat از بازی‌هایش با استخر مرجع می‌آید و ما عضو آن استخر نیستیم $\Rightarrow$ عدد 53.8 او ثابت است و ما تکانش نمی‌دهیم.

یعنی معیار اصلاً نسبی نیست

میانگین مطلوبیت خودمان روی استخر مرجع $53.8 >$

پس جمله‌ی محروم‌سازی فقط هزینه بود بدون عایدی. با حذفش شکل‌دهی پاداش دوباره کاملاً پتانسیل پایه شد $\Rightarrow$ طبق Ng, Harada & Russell سیاست بهینه را عوض نمی‌کند، و عامل دقیقاً همان کمیتی را بیشینه می‌کند که برد می‌سجد.

چک‌پوینت	امتیاز	ایران	آمریکا
آپلود ۱ (استخر سه‌تایی)	52.9	72.3	33.4
آپلود ۲ (استخر برد، بدون جریمه)	56.8	71.7	42.0
آپلود ۳ (+ کهن‌الگوی صبور)	58.8	71.3	46.3
بنچ‌مارک استاد (MasterAgent)	56.3	65.7	46.9
TitForTat (معیار دستورالعمل)	53.8	69.7	37.9

هر دو معیار رد شد — هم TitForTat و هم بنچ‌مارک استاد.

تمام بهبود از صندلی آمریکا آمد (33.4 → 46.3)؛ صندلی ایران تقریباً ثابت ماند.

یافته‌ی ۱۱: برون‌یابی را با درون‌یابی اشتباه نگیرید

برآوردگر ما برای آپلود سوم 64.8 گفت، برد 58.8 داد. ولی خودش کنار عددش نوشته بود:

«این کاندیدا 27.9 واحد بیرون از بازه‌ی لنگرهاست $\Rightarrow$ برون‌یابی است نه درون‌یابی. یک جهت بدانید، نه یک عدد.»
جهت درست بود (2.0+ واقعی)، عدد غلط (8.0+ ادعا شده). با لنگر سوم معلوم شد رابطه اشباع می‌شود:

آپلود ۳	آپلود ۱	آپلود ۲	
37.2	9.2	-18.1	امتیاز جانشین صبور (آمریکا)
68.9	72.7	39.8	امتیاز واقعی دو حریف نامعلوم

برازش خطی 106.2 می‌گفت، واقعیت 68.9 — همان 6 واحد خطا. برآوردگر حالا بین لنگرها درون‌یابی تکه‌خطی می‌کند و بیرون از بازه امتناع می‌کند.

کل خطا در دو ردیف نشست

حریف	برد واقعی	بازسازی	
MasterAgent ,Hawk ,TitForTat ,Random	—	هر چهار تا دقیق	
Dove	64.6 / 104.9	143.3 / 152.8	غلط
BayesianThreshold	15.0 / 60.9	34.3 / 76.4	غلط

هیچ مقداری از پارامترها هر دو آپلود را نمی‌سازد $\Rightarrow$ چیز گم‌شده پارامتر نبود. پس رفتار خودمان را اندازه گرفتیم:

مقابل حریف کاملاً منفعل	آپلود ۱	آپلود ۲
میانگین سیگنال	0.06	0.75
کسر مراحل HOLD	0.24	0.96
خودمان اول خارج می‌شویم	0.24	0.00

pool board - کل دیکشنری حریف‌ها را عوض کرد $\Rightarrow$ Patient و Plateau بی‌سروصدا افتادند.

عامل یاد گرفت تسلیم شدن هزینه‌ای ندارد، چون دیگر هیچ‌کس نبود که فقط بایستد و صبر کند. بهایش روی برد 13 $\approx$ واحد بود.

درسِ عملی

این دسته خطا را با امتیاز پیدا نمی‌کنید — امتیاز کل بالا رفت. با اندازه‌گیری رفتار پیدا می‌کنید.

و وقتی بازسازی جواب نمی‌دهد، دنبال جانشینِ هم‌ترتیب بگردید: Patient تنها حریف محلی است که دو آپلود ما را به همان ترتیبِ برد می‌چیند (43.3 / -18.6 - در برابر 71.3 / -39.5). سطحش شبیه نیست و ادعایی هم نمی‌کنیم — برای انتخاب ترتیب کافی است.

هر ۱۶ ویژگی، پسین ما روی تیپ ساختاری $\theta_j = (\bar{\rho}_j, \bar{m}_j)$ بود. ولی Patient و Random تیپ متفاوتی ندارند — قاعده‌شان فرق دارد، و تفاوتشان در نوسان سیگنال است.

حریف	انحراف معیار	پیشینه	کسر سکوت
Random	0.159	0.642	0.225
Dove, Patient	0.000	0.000	1.000
Hawk	0.000	1.000	0.000

سه آماره‌ی خام اضافه شد ($\rightarrow$ ۱۹ ویژگی) و پیش از آموزش تایید شد که جدا می‌کنند.

نتیجه نصفه بود

هدف اصلی (Random/آمریکا: $62.1 \rightarrow 113.3$) حاصل نشد (64.1). سود از جای دیگر آمد: ایران مقابل TitForTat $41.1 \rightarrow 34.6$ و مقابل Hawk $22.8 \rightarrow 12.1$ — بهترین عدد کل پروژه.
بازنمایی شرط لازم بود، نه کافی.

بعد از 61.7، دوازده چک‌پوینت دیگر آموزش دادیم. هیچ‌کدام بهتر نشد.

چیزی که آزمودیم	بهترین تخمین
تعادل استخر	59.2
ویژگی «چقدر شاهد داریم»	59.7
مواجهه‌ی اسکریتی 56% → 85%	61.0
تنظیم میانی	59.6
هشت بذر تازه از همان دستور	59.4

توزیع خانواده‌ی ۱۹-ویژگی‌ای (14 چک‌پوینت):

کمینه 51.5 میانه 58.7 $\sigma = 2.33$ بیشینه 61.7

چک‌پوینت ارسالی 1.5σ بالای میانگین خانواده‌ی خودش است. 61.7 کف این روش نیست، سقف خوش‌شانسی‌اش است.

۱. حلقه‌ی تعهد: تشدید $\Rightarrow q^* \downarrow \Rightarrow (B - X) \uparrow \Rightarrow K \uparrow \Rightarrow$ ادامه عقلانی‌تر.

۲. حلقه‌ی شکنندگی: فرسایش $\Rightarrow g \uparrow \Rightarrow m \downarrow \Rightarrow$ فرسایش سریع‌تر.

۳. حلقه‌ی میانجی: تشدید $\Rightarrow$ پنجره بسته $X \Rightarrow$ پایین $\Rightarrow$ خروج غیرممکن‌تر.

و تنها چیزی که هر سه را می‌شکند

خویشتن‌داری متقابل — چون هم‌زمان K را می‌خواباند، سوخت را کم می‌کند، و پنجره‌ی میانجی‌گری را باز می‌کند.

محدودیت اصلی: مدل درباره‌ی جهت روابط قابل دفاع است، نه درباره‌ی اندازه‌شان.